Construção de Data Warehouse

Projeto LH Nautical

Relatório Técnico

Candidato:
Alex P. F.

Programa:
Desafio Lighthouse - Dados e IA

24 de março de 2026

Sumário Executivo

Este relatório apresenta a construção de um Data Warehouse completo para a empresa LH Nautical, como parte de um projeto end-to-end na área de Dados.

O objetivo principal foi desenvolver uma estrutura robusta que permitisse a ingestão, tratamento, organização e disponibilização de dados para análise e suporte à tomada de decisão. O projeto abrangeu desde dados brutos até a modelagem final em formato analítico.

A arquitetura adotada foi baseada no modelo Medallion (Bronze, Silver e Gold), com foco em clareza, rastreabilidade e simplicidade, evitando complexidade desnecessária. O processo incluiu:

- Ingestão de dados a partir de arquivos CSV e JSON
- Padronização e limpeza de dados na camada Silver
- Modelagem dimensional na camada Gold (Star Schema)
- Integração de dados externos (taxa de câmbio)
- Implementação de validações de qualidade e consistência

O Data Warehouse final é composto por tabelas dimensionais e factuais, permitindo análises de vendas, custos e comportamento de produtos ao longo do tempo. Destaca-se também a incorporação de uma dimensão temporal e de uma tabela de câmbio, possibilitando análises financeiras mais sofisticadas.

Como resultado, foi construída uma base de dados confiável, organizada e pronta para consumo por ferramentas de análise, como Python e Power BI.

Este documento descreve de forma resumida as decisões técnicas, a arquitetura adotada e os principais resultados obtidos ao longo da etapa de Engenharia de Dados do projeto.

1 Visão Geral do Projeto

Este projeto consiste no desenvolvimento de um pipeline de dados completo para a construção de um Data Warehouse para a empresa LH Nautical, com o objetivo de organizar seus dados operacionais em uma base confiável e orientada à análise.

O objetivo principal foi estruturar uma base de dados confiável e organizada, capaz de suportar análises de negócio, modelagem e geração de insights, abrangendo todas as etapas do ciclo de dados.

O escopo do projeto inclui:

- Ingestão de dados a partir de múltiplas fontes e formatos
- Construção de um pipeline estruturado em camadas (Bronze, Silver e Gold)
- Limpeza, padronização e validação dos dados
- Modelagem dimensional para suporte a análises
- Integração de dados externos para enriquecimento do modelo

As principais tecnologias utilizadas foram:

- PostgreSQL (ambiente de banco de dados)
- Docker (containerização do ambiente)
- DBeaver (interface de desenvolvimento)
- Python (processamento inicial de dados)

O projeto foi desenvolvido com foco em simplicidade, clareza e boas práticas de engenharia de dados, evitando complexidade desnecessária e priorizando a rastreabilidade e a qualidade das informações.

Como resultado, foi construída uma estrutura de Data Warehouse completa, preparada para suportar as etapas subsequentes de análise exploratória, modelagem preditiva e visualização de dados.

2 Fontes de Dados

O Data Warehouse foi construído a partir de múltiplas fontes de dados, com diferentes formatos e origens, simulando um cenário real de integração de dados heterogêneos.

Os dados utilizados no projeto podem ser divididos em três grupos principais:

2.1 Dados Operacionais

Os dados operacionais representam as principais entidades de negócio da empresa, incluindo clientes, produtos e vendas.

- **clients_crm (JSON)**: Contém informações cadastrais dos clientes, como nome, localização e e-mail. O arquivo foi convertido para o formato CSV para facilitar a ingestão no banco de dados.
- **produtos_raw (CSV)**: Contém informações dos produtos, incluindo nome, preço de venda, código e categoria. Este dataset apresentou alta inconsistência nas categorias, exigindo tratamento significativo nas etapas posteriores.
- **vendas_2023_2024 (CSV)**: Contém registros transacionais de vendas, incluindo cliente, produto, quantidade, valor total e data da venda. Este dataset serviu como base para a construção da tabela de fatos principal.

2.2 Dados de Custos

Os dados de custos representam o histórico de preços de aquisição dos produtos, sendo fundamentais para análises de rentabilidade.

- **custos_importacao (JSON)**: Estruturado com dados históricos de preços de importação em dólar (USD), incluindo múltiplas entradas por produto ao longo do tempo. O arquivo foi previamente transformado em CSV, resultando em uma estrutura tabular com granularidade temporal.

2.3 Dados Externos

Para enriquecer o modelo analítico, foi incorporada uma fonte externa de dados econômicos.

- **exchange_rates_bcb (CSV)**: Dataset contendo a cotação diária do dólar (USD/BRL), obtido via Python a partir de fontes públicas. Os dados foram integrados ao Data Warehouse e tratados para garantir continuidade temporal, incluindo preenchimento de datas não úteis.

A utilização de múltiplas fontes, incluindo dados internos e externos, permitiu a construção de um modelo mais robusto, capaz de suportar análises financeiras mais completas, como conversão de custos e cálculo de margens.

3 Arquitetura do Data Warehouse

A arquitetura do Data Warehouse foi baseada em uma abordagem simplificada do modelo Medallion, composta por três camadas principais: Bronze, Silver e Gold. Essa estrutura foi escolhida por sua clareza, rastreabilidade e capacidade de organizar o fluxo de dados de forma progressiva, desde dados brutos até estruturas analíticas.

O pipeline foi projetado com foco em simplicidade e transparência, evitando complexidade desnecessária, como orquestração avançada ou ferramentas externas de gestão de fluxo, mantendo toda a lógica centralizada em SQL.

3.1 Visão Geral da Arquitetura

A Figura 1 apresenta uma visão geral do fluxo de dados ao longo das camadas do Data Warehouse.

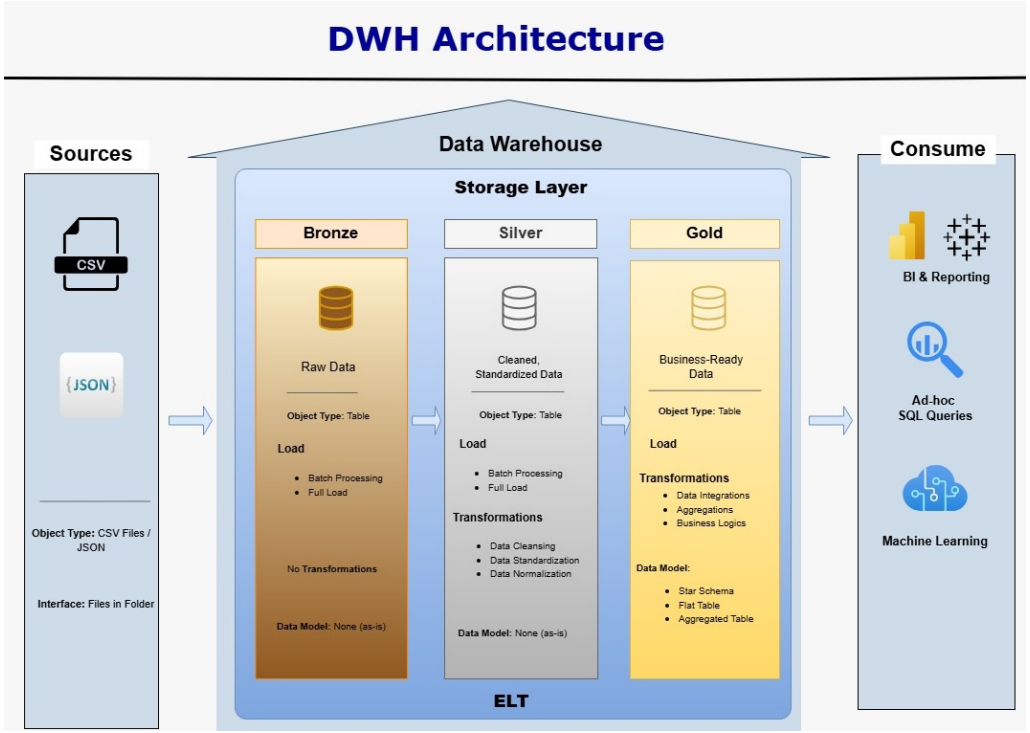

Figura 1: Arquitetura do Data Warehouse baseada no modelo Medallion

3.2 Camada Bronze

A camada Bronze é responsável pela ingestão dos dados brutos no banco de dados, sem qualquer transformação significativa. Todos os dados foram carregados exatamente como recebidos, preservando seu formato original.

As principais características desta camada incluem:

- Armazenamento dos dados em formato textual (TEXT)
- Uso de operações de carga em massa (COPY)
- Preservação completa dos dados originais para rastreabilidade

Essa abordagem garante que qualquer transformação posterior possa ser auditada e reproduzida a partir da fonte original.

3.3 Camada Silver

A camada Silver tem como objetivo a limpeza, padronização e preparação dos dados para uso analítico.

Nesta etapa, foram aplicadas transformações como:

- Conversão de tipos de dados (casting)
- Tratamento de valores inconsistentes e formatação de campos
- Padronização de textos (como categorias e localizações)
- Remoção de duplicidades exatas

Importante destacar que as transformações nesta camada foram majoritariamente sintáticas, evitando inferências complexas ou decisões de negócio definitivas, que foram postergadas para a camada Gold.

3.4 Camada Gold

A camada Gold representa o modelo final de consumo, estruturado para análise e geração de insights. Nesta etapa, os dados foram organizados em um modelo dimensional (Star Schema), com separação clara entre tabelas de fatos e dimensões.

As principais tabelas criadas incluem:

- Dimensões: clientes, produtos, datas e taxa de câmbio
- Fatos: vendas e custos de importação

Além disso, nesta camada foram aplicadas regras de negócio mais estruturadas, como a normalização semântica de categorias de produtos e a integração com dados externos.

Essa organização permite consultas analíticas eficientes e facilita a integração com ferramentas de visualização e análise de dados.

3.5 Considerações de Projeto

O Data Warehouse foi desenvolvido com foco em:

- Clareza e organização do fluxo de dados
- Separação de responsabilidades entre as camadas
- Facilidade de manutenção e extensão futura
- Preparação para consumo analítico (Python, BI)

A adoção dessa arquitetura permitiu construir uma base sólida, confiável e escalável, adequada para suportar as etapas subsequentes de análise e modelagem.

4 Modelagem Dimensional

A camada Gold do Data Warehouse foi estruturada utilizando um modelo dimensional no formato Star Schema, com o objetivo de otimizar consultas analíticas e facilitar a interpretação dos dados.

Nesse modelo, os dados são organizados em tabelas de fatos e dimensões, permitindo análises eficientes e intuitivas, especialmente em ferramentas de Business Intelligence.

4.1 Visão Geral do Modelo

A Figura 2 apresenta o modelo dimensional final construído para o projeto.

4.2 Tabelas de Dimensão

As tabelas de dimensão armazenam atributos descritivos que contextualizam os dados das tabelas de fatos.

- **dim_customer**: Contém informações dos clientes, incluindo nome, e-mail e localização (cidade e estado). A estrutura foi derivada da camada Silver, com normalização adicional dos dados de localização.
- **dim_product**: Armazena os produtos disponíveis para venda, incluindo nome, categoria e preço de tabela. Nesta tabela foi realizada a padronização semântica das categorias, consolidando múltiplas variações em três categorias principais.

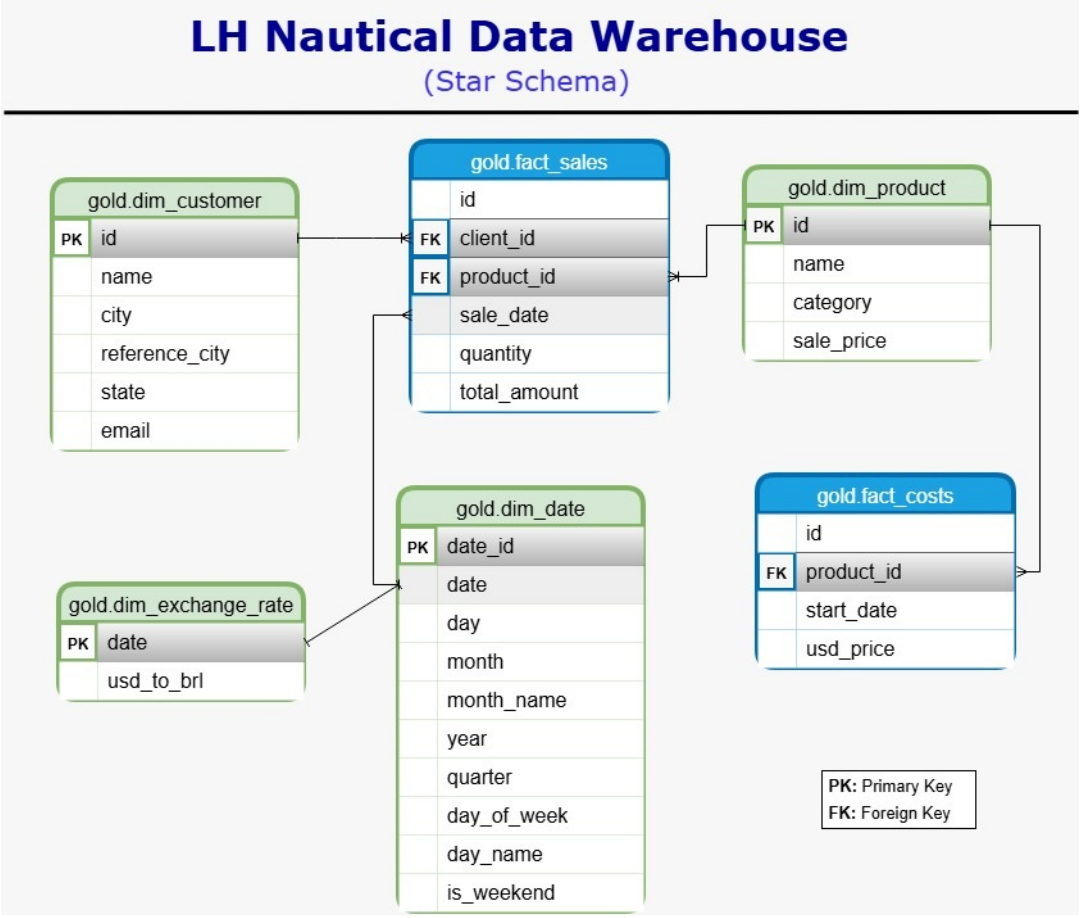

Figura 2: Modelo dimensional (Star Schema) do Data Warehouse

- **dim_date**: Tabela de datas que fornece atributos temporais, como dia, mês, ano, trimestre e indicadores de fim de semana. Essa dimensão permite análises temporais mais flexíveis e eficientes.

- **dim_exchange_rate**: Contém a cotação diária do dólar (USD/BRL), permitindo a conversão de custos de importação para moeda local. Foi aplicado um processo de preenchimento para garantir a continuidade temporal, incluindo datas sem cotação oficial.

4.3 Tabelas de Fato

As tabelas de fato armazenam eventos de negócio e suas métricas associadas.

- **fact_sales**: Representa as transações de vendas, contendo informações como cliente, produto, quantidade, valor total e data da venda. Esta é a principal tabela para análise de receita.

- **fact_costs**: Armazena o histórico de custos de importação dos produtos ao longo do tempo, em dólar (USD), com granularidade por produto e data de vigência do custo.

4.4 Relacionamentos e Granularidade

O modelo foi construído respeitando a granularidade de cada tabela de fato:

- **fact_sales**: granularidade por venda individual
- **fact_costs**: granularidade por produto e data de início do custo

As tabelas de fato se conectam às dimensões por meio de chaves substitutas, permitindo consultas eficientes e garantindo integridade referencial.

4.5 Considerações de Modelagem

Durante a construção do modelo, algumas decisões importantes foram tomadas:

- Separação entre preço de venda (dimensão) e valor efetivo da venda (fato), permitindo a identificação de descontos
- Manutenção de custos em moeda original (USD), com conversão realizada via tabela de câmbio
- Não duplicação de atributos descritivos nas tabelas de fato, evitando redundância e inconsistência

Essa modelagem proporciona flexibilidade analítica e permite a construção de métricas mais avançadas, como margem de lucro e análise temporal de custos e receitas.

5 Validação e Qualidade dos Dados

Após a construção da camada Gold, foram realizados diversos testes de validação com o objetivo de garantir a integridade, consistência e confiabilidade do Data Warehouse.

Essas validações foram estruturadas em um script dedicado, permitindo a verificação sistemática dos dados finais antes de sua utilização para análise.

5.1 Validação de Integridade Referencial

Foram realizados testes para garantir que todas as chaves estrangeiras presentes nas tabelas de fatos possuem correspondência válida nas tabelas de dimensão.

Em particular, foram verificadas as relações entre:

- **fact_sales** e **dim_customer**
- **fact_sales** e **dim_product**
- **fact_costs** e **dim_product**

Os resultados indicaram consistência total, sem registros órfãos, garantindo a integridade do modelo dimensional.

5.2 Validação de Consistência de Métricas

Uma das principais validações realizadas consistiu na comparação entre o valor total registrado nas vendas e o valor esperado com base na quantidade e no preço de tabela dos produtos.

O cálculo esperado segue a relação:

$$\text{valor esperado} = \text{quantidade} \times \text{preço do produto}$$

A análise revelou que apenas uma pequena parcela das transações apresentou correspondência exata entre os valores. No entanto, a maioria das diferenças observadas foi de pequena magnitude, atribuída a efeitos de arredondamento.

Por outro lado, foram identificadas divergências mais significativas, predominantemente negativas, indicando que o valor efetivo das vendas é, em muitos casos, inferior ao valor de referência calculado a partir do preço de tabela.

Esse comportamento sugere a aplicação de descontos nas transações, evidenciando que o preço armazenado na dimensão de produtos representa um valor de referência, e não necessariamente o valor final de venda.

5.3 Validação de Dados Temporais

As colunas de data foram verificadas quanto à consistência de formato e abrangência temporal. Destaca-se que:

- As vendas cobrem o período de 2023 a 2024
- Os custos de importação possuem histórico mais amplo, de 2016 a 2025

Adicionalmente, a integração com a tabela de câmbio garantiu a existência de valores para todas as datas, incluindo fins de semana, por meio de preenchimento baseado na última cotação disponível.

5.4 Considerações Finais

As validações realizadas indicam que o Data Warehouse apresenta um alto nível de qualidade e consistência, estando adequado para suportar análises exploratórias, modelagem e construção de dashboards.

Eventuais diferenças identificadas nos dados refletem características reais do processo de negócio, como descontos em vendas, e não inconsistências estruturais do pipeline.

6 Conclusão

Este projeto teve como objetivo a construção de um Data Warehouse completo para a empresa fictícia LH Nautical, abrangendo todas as etapas fundamentais de um pipeline de dados, desde a ingestão de dados brutos até a disponibilização de uma estrutura analítica pronta para consumo.

A adoção de uma arquitetura baseada no modelo Medallion permitiu organizar o fluxo de dados de forma clara e rastreável, garantindo separação de responsabilidades entre as camadas Bronze, Silver e Gold. Ao longo desse processo, foram aplicadas práticas de engenharia de dados voltadas à limpeza, padronização e validação das informações.

Na camada final, a modelagem dimensional em formato Star Schema possibilitou a estruturação eficiente dos dados, com tabelas de fatos e dimensões bem definidas, adequadas para análises de negócio. A integração de dados externos, como a cotação do dólar, agregou valor ao modelo, permitindo análises financeiras mais completas.

As validações realizadas indicaram que o Data Warehouse apresenta consistência estrutural e qualidade suficiente para suportar análises exploratórias, modelagem preditiva e construção de dashboards. Além disso, foram identificados comportamentos relevantes nos dados, como a presença de descontos nas vendas, evidenciando o potencial analítico da base construída.

Como resultado, foi desenvolvida uma solução robusta, organizada e extensível, que atende aos objetivos propostos e estabelece uma base sólida para as etapas subsequentes do projeto, incluindo análise de dados, modelagem e geração de insights.